

Лабораторная работа 4

Полносвязная сеть своими руками на CPU
Бинарный классификатор Banknote Authentication

Выполнил	Группа	Дата
Тоц Леонид Александрович	ИВТ-2	06.10.2026

Цель и постановка задачи

Реализовать многослойный перцептрон (MLP), прямой и обратный проходы вручную, обучить его mini-batches на CPU и оценить качество на независимой тестовой выборке. Выбран вариант бинарной классификации из разрешённого списка задания.

1. Датасет и подготовка

Banknote Authentication: 1372 записи, 4 числовых признака, одна целевая переменная $class \in \{0, 1\}$. Признаки получены из изображений образцов банкнот. Положительным считается исходный класс 1; исходные метки не переименованы. Пропусков нет.

Признак	Содержание
variance	Дисперсия вейвлет-преобразованного изображения
skewness	Асимметрия вейвлет-преобразованного изображения
curtosis	Эксцесс вейвлет-преобразованного изображения
entropy	Энтропия изображения

До разбиения удалены 24 полных дубликата. Осталось 1348 уникальных записей: 738 класса 0 и 610 класса 1. Одинаковые признаки с противоречащими метками не обнаружены. Разбиение стратифицированное, около 60/20/20, seed=42.

Часть	Записей	Класс 0	Класс 1
train	809	443	366
val	270	148	122
test	269	147	122

Источник: Volker Lohweg (2012), UCI Machine Learning Repository. DOI: [10.24432/C55P57](https://doi.org/10.24432/C55P57). Лицензия данных: CC BY 4.0. Файл сохранён локально без изменения значений.

2. Математическая модель

Стандартизация

Средние μ и стандартные отклонения s (ddof=0) вычислены только по train. Для val и test применяются те же параметры: $x'_j = (x_j - \mu_j) / s_j$. При $s=0$ используется масштаб 1. Это исключает утечку информации из val/test при предобработке.

Прямой проход и размерности

Объекты расположены по строкам. Для батча из m объектов A_0 имеет размер $m \times 4$. Сеть содержит два скрытых слоя: $4 \rightarrow 32 \rightarrow 16 \rightarrow 1$. Матрицы весов имеют размеры 4×32 , 32×16 , 16×1 ; смещения - 1×32 , 1×16 , 1×1 . Всего 705 параметров.

$$Z_l = A_{l-1} W_l + b_l$$

$$A_l = \max(0, Z_l) \text{ для скрытых слоёв}$$

$$p = \sigma(Z_L) = 1 / (1 + \exp(-Z_L))$$

Функция потерь и L2

$$J = (1/m) \sum_i [\log(1 + \exp(z_i)) - y_i z_i] + (\lambda/2) \sum_l \|W_l\|_F^2$$

Первая часть - бинарная кросс-энтропия (BCE). Она вычисляется через $\text{pr.logaddexp}(0, z)$, чтобы избежать $\log(0)$ и переполнения $\exp$. Сигмоида вычисляется отдельно для $z \geq 0$ и $z < 0$.

L2-регуляризация с $\lambda=0.0001$ применяется к весам, но не к смещениям.

Ручное обратное распространение ошибки

$$D_L = (p - y) / m$$

$$D_l = (D_{l+1} W_{l+1}^T) \odot f'(Z_l)$$

$$\nabla W_l = A_{l-1}^T D_l + \lambda W_l$$

$$\nabla b_l = \sum_i D_{l,i}$$

Для ReLU $f'(z)=1$ при $z>0$ и 0 при $z\leq 0$. В коде также поддерживается tanh с производной $1 - \tanh^2(z)$. Деление на фактический размер батча выполняется один раз в D_L ; повторное усреднение в ∇W не требуется. Последний батч содержит 9 объектов. Все градиенты вычисляются до изменения любого веса.

3. Протокол обучения и логирование

Параметр	Значение
Архитектура / активации	$4 \rightarrow 32 \rightarrow 16 \rightarrow 1$; ReLU / sigmoid
Инициализация	Не для скрытых ReLU; Xavier для выхода; bias=0
Оптимизатор	Самописный SGD с моментом: $\beta=0.9$, $\eta=0.03$
Mini-batch / максимум эпох	32 / 150
L2 / ранняя остановка	$\lambda=0.0001$; patience=20; min_delta=0.00001
Критерий лучшей модели	Минимальная BCE на val; восстановление весов
Seed	Разбиение=42; инициализация=42; перемешивание=43
Устройство / арифметика	CPU, NumPy, float64

Обновление параметров: $v \leftarrow \beta v + g$; $\theta \leftarrow \theta - \eta v$. Для каждого веса и смещения хранится свой вектор момента. Перед каждой эпохой train перемешивается. Гиперпараметры зафиксированы до тестовой оценки; перебор по test не выполнялся.

Последовательность эксперимента

1. Проверить файл, удалить полные дубликаты, сформировать train/val/test.
2. Обучить стандартизацию на train и применить её к трём частям.
3. На каждом mini-batch выполнить forward $\rightarrow$ BCE $\rightarrow$ backward $\rightarrow$ SGD.
4. После эпохи вычислить train/val BCE и Accuracy, записать историю.
5. По val BCE сохранить лучший чекпойнт; при отсутствии значимого улучшения 20 эпох остановиться.
6. Восстановить лучшую модель, выбрать порог по val F1 и один раз оценить test.

История в pandas.DataFrame

Столбцы: epoch, loss, val_loss, accuracy, val_accuracy, objective. loss и val_loss - BCE без L2; objective - train BCE с L2. Accuracy в истории вычисляется при фиксированном пороге 0.5. Метрики считаются на полных train/val после обновлений эпохи, а не как невзвешенное среднее ошибок батчей.

История сохранена в artifacts/history.csv. model.npz содержит веса, смещения, архитектуру, параметры стандартизации и порог. Индексы разбиения и прогнозы test сохраняются отдельно. Готовые MLP, PyTorch, TensorFlow и autograd не используются.

4. Кривые обучения и сходимости




Рис. 1. BCE и Accuracy на train/val. Вертикальная линия - лучшая эпоха 149.

Эпоха	Train BCE	Val BCE	Train acc.	Val acc.
1	0.221315	0.274572	0.9085	0.8778
10	0.005453	0.005187	1.0000	1.0000
50	0.000745	0.000573	1.0000	1.0000
100	0.000385	0.000292	1.0000	1.0000
149	0.000299	0.000224	1.0000	1.0000
150	0.000298	0.000225	1.0000	1.0000

До обучения BCE составляла 0.728182 на train и 0.742479 на val. К 10-й эпохе Accuracy на обеих частях достигла 1.0; последующее уменьшение BCE отражает рост уверенности прогнозов.

Обучение завершилось по лимиту 150 эпох. Ранняя остановка была включена, но её условие не сработало. Минимум val BCE получен на эпохе 149: 0.000224. Именно её веса восстановлены для итоговой оценки; график сохраняет все 150 эпох.

На кривой val не наблюдается систематического роста ошибки при уменьшении train BCE. Явных признаков переобучения в этом запуске нет. Однако одно разбиение не доказывает полного отсутствия переобучения; L2 и выбор чекпойнта по val остаются средствами контроля.

Порог решения

$\hat{y}=1[p \geq \tau]$. Порог не входит в функцию обучения. Он выбран по максимальному F1 на val среди середин между уникальными вероятностями, крайних допустимых значений и 0.5. При равном F1 выбирается ближайший к 0.5 порог, затем меньший. Максимум F1=1 достигается при $\tau=0.5$, поэтому выбран этот порог.

5. Итоговые метрики и графики

Часть	BCE	Accuracy	F1	ROC-AUC	AP
train	0.000299	1.0000	1.0000	1.0000	1.0000
val	0.000224	1.0000	1.0000	1.0000	1.0000
test	0.000446	1.0000	1.0000	1.0000	1.0000

На test из 269 объектов: TN=147, TP=122, FP=0, FN=0. Precision=Recall=1.0. Использован чекпойнт эпохи 149 и $\tau=0.5$, зафиксированные по val. Повторного обучения на train+val нет.




Рис. 2. ROC и PR на test. AP - Average Precision, а не трапецевидная площадь PR.




Рис. 3. Матрица ошибок test и выбор порога по F1 на val.

Accuracy=(TP+TN)/N; $F1=2TP/(2TP+FP+FN)$. ROC-AUC вычислена по всем порогам трапецевидным интегрированием ROC. AP вычислена как сумма Precision· Δ Recall по группам одинаковых оценок. ROC-AUC и AP получены из вероятностей, а не бинарных прогнозов.

6. Проверка реализации и вывод

Численные градиенты и независимые тесты

Центральная разность с $\epsilon=10^{-6}$ проверена для всех 47 параметров сети $4 \rightarrow 5 \rightarrow 3 \rightarrow 1$, для ReLU и tanh, с L2=0.07. Для ReLU выбраны ненулевые смещения и точки вдали от $z=0$: в точке излома центральная разность не обязана совпадать с принятой в коде односторонней производной.

Активация	Параметров	Макс. $ \Delta g $	Отн. L2-ошибка
relu	47	1.485e-10	6.333e-10
tanh	47	1.169e-10	6.149e-10

13 тестов пройдены. Проверены градиенты с L2 и без неё, однократное усреднение по батчу, устойчивость при логитах ± 1000 , непересечение частей и удаление дубликатов, стандартизация, подбор порога, восстановление раннего лучшего чекпойнта и загрузка модели.

Accuracy/F1/ROC-AUC/AP независимо сверены со scikit-learn, включая равные вероятности; scikit-learn используется только в тестах.

Вывод

Цель выполнена: реализован собственный MLP с ручным backpropagation и обучением mini-batches на CPU. При $\tau=0.5$ все 269 тестовых записей классифицированы верно; Accuracy=F1=ROC-AUC=AP=1.0, BCE $\approx$ 0.000446. Результат воспроизводится из локального датасета с фиксированными seed и сохранённой моделью.

Высокое качество относится к одному небольшому датасету и одному разбиению. Оно не гарантирует отсутствие ошибок на данных из других источников. Для более устойчивой оценки полезны повторные стратифицированные разбиения или кросс-валидация с подбором параметров внутри обучающих частей.

Воспроизводимость

Запуск из lab4: `python experiment.py`. Проверки: `python -m pytest -q tests`. Ноутбук Тоц_ЛА_ИВТ-2_ЛР4_MLP.ipynb содержит выполненные ячейки, таблицы и графики. Полный протокол, версии библиотек и SHA-256 данных записаны в artifacts/results.json.

Источники

- Lohweg, V. (2012). Banknote Authentication. UCI. [Страница датасета](#); DOI: 10.24432/C55P57. Дата обращения: 06.10.2026.
- Материалы преподавателя (Dmitry Vlasov, 2025): «Лабораторная работа 4 - самописный MLP на CPU»; протокол и логирование истории; псевдокод, алгоритм и вывод формул backpropagation с mini-batches; справочник метрик классификации и регрессии.
- Everton Gomedé. Understanding Backpropagation: The Engine Behind Neural Network Learning (30.09.2023), предоставленный учебный материал.